

ByteTrack Nesne Takip Algoritmasının Sisli ve Puslu Havalardaki Performansı ve İyileştirilmesi

1. Giriş

Çoklu nesne takibi (ÇNT), otonom sürüş, gözetim, robotik ve daha pek çok alanda uygulamaları olan temel bir bilgisayarla görme görevidir. Doğru ve sağlam ÇNT, bu uygulamaların güvenliğini ve güvenilirliğini sağlamada kritik bir rol oynar. Ancak sisli ve puslu hava koşulları, görüntü kalitesini ciddi şekilde düşürerek ÇNT algoritmaları da dâhil olmak üzere görme tabanlı sistemlerin performansını olumsuz etkiler. Bu tür olumsuz hava koşulları, görüntü kalitesinde azalmaya, kontrast düşüklüğüne, renk bozulmasına ve artan gürültüye neden olur.^[1-2] ByteTrack, basitliği ve etkinliği ile bilinen son teknoloji bir ÇNT algoritmasıdır. Temel yeniliği, düşük güvenilirlikli olanlar da dâhil olmak üzere tüm tespit kutularını ilişkilendirmesidir.^[3-4] Bu raporun amacı, ByteTrack'in sisli ve puslu koşullardaki performansını araştırmak ve mevcut araştırmalara dayanarak potansiyel iyileştirme stratejilerini keşfetmektir.

2. ByteTrack Algoritması Hakkında

ByteTrack'in metodolojisi iki aşamalı bir ilişkilendirme sürecine dayanır. İlk olarak, yüksek güvenilirlikli tespitler ilişkilendirilir. Ardından, düşük güvenilirlikli tespitler potansiyel olarak kaçırılan nesneleri kurtarmak ve iz sürekliliğini sağlamak için kullanılır.^[3-4] Algoritma, nesne durumlarını tahmin etmek için bir Kalman filtresi kullanır.^[4] İlişkilendirme için benzerlik metrikleri (örneğin, Kesişim Üzerinden Birleşim - IoU) kullanılır.^[1] ByteTrack'in temel yeniliği, diğer takipçiler tarafından genellikle atılan düşük güvenilirlikli tespitleri kullanmasıdır.^[3] Bu, özellikle düşük görüş koşullarında ilgili olan, tıkanan veya kötü tespit edilen nesnelerin izlerini sürdürmeye yardımcı olur.^[3] ByteTrack, çeşitli nesne algılama modelleriyle (örneğin, YOLO, Faster R-CNN, DETR) çalışacak şekilde esnektir. Orijinal ByteTrack makalesinde varsayılan dedektör olarak yaygın olarak YOLOX kullanılmaktadır.^[1,11,15]

ByteTrack'in temel gücü, düşük güvenilirlikli tespitleri ilişkilendirme yeteneğinde yatar. Sisli ve puslu koşullarda, nesne algılama güvenilirliği genellikle daha düşüktür. Yalnızca yüksek güvenilirlikli tespitleri kullanan takipçiler bu nesneleri kaçırabilir ve bu da parçalanmış izlere yol açar. ByteTrack'in bu düşük güvenilirlikli tespitleri ikincil bir ilişkilendirme adımı için kullanma mekanizması, aksi takdirde kaybolabilecek gerçek nesneleri kurtararak bu sorunu potansiyel olarak azaltabilir. Ancak, ByteTrack'in performansı, temel nesne algılama algoritmasının doğruluğuna büyük ölçüde bağlıdır. Bu nedenle, sis ve pusun nesne algılama üzerindeki zorlukları doğrudan ByteTrack'in takip performansını etkileyecektir. İlk tespitlerin kalitesi, takip sürecinin temelini oluşturur.^[16]

3. Sis ve Pusun Nesne Takibi Üzerindeki Etkileri

Sis ve pus, görsel verileri çeşitli şekillerde etkiler. Atmosferdeki partiküllerin ışığı saçması, kontrastın ve görüşün azalmasına neden olur. Bu durum renklerin solmasına ve bozulmasına yol açabilir. Ayrıca, görüntülerde bulanıklık ve gürültü artar. Görüntü kalitesindeki bu bozulma, nesne algılama algoritmaları için çeşitli zorluklar yaratır. Tespit doğruluğu azalır, bu da daha fazla yanlış negatife (kaçırılan nesneler) ve yanlış pozitiflere (yanlış tespit edilen nesneler) yol açar. Tespit edilen nesneler için güvenilirlik puanları düşer, bu da takipçilerin bunları çerçeveler arasında ilişkilendirmesini zorlaştırır. Görüş mesafesindeki sınırlamalar nedeniyle küçük ve uzak nesneleri tespit etmek zorlaşır.

Bu algılama zorlukları nesne takibine de yansır. Kimlik geçişleri (nesnelere çerçeveler arasında yanlış kimlikler atanması) artar. Parçalanmış yörüngeler (bir nesnenin izinin birden çok kısma bölünmesi) daha sık görülür. Çoğunlukla kaybolan (ML) nesne örnekleri artar. Sis ve pus, görüntü bozulmasından başlayıp zayıf nesne algılamasına ve sonuç olarak güvenilir nesne takibine yol açan bir dizi olumsuz etki yaratır. Bu koşullarda takip performansını artırmak için ilk görüntü kalitesini ve algılama doğruluğunu ele almak çok önemlidir. Ayrıca, sis ve pus görüntünün farklı bölümlerini ve içindeki nesneleri eşit olmayan bir şekilde etkileyebilir, bu da tek tip düzeltme yöntemlerinin uygulanmasını zorlaştırır. Sis yoğunluğu bir sahne boyunca değişebilir (heterojen sis) ve bazı alanlar diğerlerinden daha fazla gizlenebilir. Benzer şekilde, farklı mesafelerdeki veya değişen tıkanma seviyelerindeki nesneler sis ve pusan farklı şekilde etkilenebilir ve daha karmaşık ve uyarlanabilir işleme yöntemleri gerektirebilir.

4. ByteTrack'in Sis ve Pus Altındaki Performans Analizi (Mevcut Araştırmalara Göre)

ByteTrack'in standart sisli veya puslu veri kümeleri üzerindeki performansını doğrudan değerlendiren belirli çalışmaların olmadığı görülmektedir. Ancak, ByteTrack'in tıkanmalar ve düşük görüş gibi sisli ve puslu koşullara benzer zorlu senaryolardaki performansı hakkında bazı bilgiler mevcuttur. ByteTrack'in düşük puanlı kutuları ilişkilendirerek tıkalı nesneleri etkili bir şekilde işleyebildiği belirtilmiştir. Bu, nesnelerin kısmen gizlendiği veya netliğin azaldığı sisli/puslu koşullarda potansiyel bir avantaj sunmaktadır. Düşük görüş koşullarında kötüleşebilen hareket bulanıklığını işleme yeteneğinden de bahsedilmektedir. Luo ve diğerleri^[13] tarafından yapılan bir araştırma, ByteTrack'in otoyol hızlandırılmış çekim videolarında SORT ve DeepSORT'tan daha iyi performans gösterdiğini göstermektedir. Bu, açıkça sis veya pus olmasa da, potansiyel olarak değişen çevresel koşullarda genel bir sağlamlığa işaret etmektedir. Zhang ve diğerleri^[7] tarafından sunulan bir çalışma, ByteTrack'in tıkanmalar ve değişen aydınlatma koşulları altında bile çok kameralı yaya takibinde etkinliğini vurgulamaktadır ve bu da bazı görsel zorluklara karşı dirençli olduğunu göstermektedir.

Bijelic ve diğerleri^[17] tarafından hazırlanan "Into the Fog: Evaluating Robustness of Multiple Object Tracking" adlı çalışmadan alınan numaralı parça, ByteTrack'i simüle edilmiş homojen ve heterojen sise karşı doğrudan değerlendirmektedir. Çalışmanın temel bulgusu, ByteTrack'in homojen sis koşullarına maruz kaldığında test edilen takipçiler arasında en yüksek sağlamlığı

gösterdiği. Sis yoğunluğu "Berrak" seviyesinden "Sis 4" seviyesine çıktıkça performans düşüşü en yavaş olan takipçi ByteTrack olmuştur. Bu durum, algoritmanın güvenilirliğe bakılmaksızın tüm tespitleri ele alma stratejisine bağlanmaktadır. Başka bir takip algoritması olan TransCenter, Sis 2'ye kadar en iyi takip performansını gösterirken, ByteTrack tüm homojen sis yoğunluğu seviyelerinde daha kademeli bir performans düşüşü sergilemiştir. Heterojen sis koşulları altında da ByteTrack iyi performans göstermiştir. Bu sonuçlar, heterojen sis yoğunluğu arttıkça performans düşse de, ByteTrack'in yine de bir dereceye kadar sağlamlık sergilediğini göstermektedir.

ByteTrack'in bir trafik etki değerlendirme sisteminde araç sayımı için kullanıldığı belirtilmektedir, bu da hava koşullarının değişebileceği gerçek dünya dış mekân senaryolarında kullanılabilirliğini ima etmektedir. Karmaşık senaryoları ve hava etkilerini de ele almayı amaçlayan geliştirilmiş bir ByteTrack tartışılmış ve bu da orijinal ByteTrack'in bu tür koşullarda sınırlamaları olabileceğini düşündürmektedir. YOLOv8 ve ByteTrack'in otonom bir tarım robotunda yabancı ot tespiti için kullanıldığı araştırma mevcut olup, bu da potansiyel olarak değişen görüş koşullarına sahip dış ortamlardaki uygulamalarını göstermektedir. ^[14]

Sağlanan parçalar gerçek dünya sis ve pus veri kümelerinde kapsamlı doğrudan değerlendirmelerden yoksun olsa da, simüle edilmiş sis üzerindeki araştırmalar, ByteTrack'in düşük güvenilirlikli tespitleri kullanma temel mekanizması sayesinde bu koşullarda bir dereceye kadar sağlamlık sergilediğini güçlü bir şekilde göstermektedir. Ancak, genel karmaşık senaryolar ve hava etkileri için bile ByteTrack'te iyileştirmelere ihtiyaç duyulması, algoritmanın güçlü olmasına rağmen, özellikle olumsuz hava koşulları için hala geliştirilebilecek yönleri olduğunu göstermektedir.

Tablo 1: Simüle Edilmiş Siste ByteTrack Performansının Özeti

Sis Yoğunluğu	Homojen Sis HOTA (%)	Homojen Sis MOTA (%)	Heterojen Sis HOTA (%)	Heterojen Sis MOTA (%)
Berrak	80.5	76.7	78.42	76.06
Sis 1	80.1	76.0	76.68	74.29
Sis 2	75.5	71.0	69.35	61.98
Sis 3	54.5	39.0	38.02	19.14
Sis 4	15.5	12.0	-	-

5. Sonuç ve Öneriler

Görüntü dehazing teknikleri, sisli ve puslu koşullarda nesnelerin görünürlüğü önemli ölçüde iyileştirilebilir, böylece ByteTrack tarafından kullanılan nesne dedektörünün performansını artırarak daha doğru ve kararlı takibe yol açar. Çok modlu sensör füzyonu, özellikle radar kullanımı, sis ve pusun bu atmosferik koşullara nüfuz etme yeteneği nedeniyle, görüş tabanlı takibin sınırlamalarının üstesinden gelmek için umut verici bir yol sunar. Radar verilerini ByteTrack ile entegre etmek, görsel olarak gizlendiklerinde bile nesnelerin varlığı, konumu ve hızı hakkında önemli bilgiler sağlayabilir. ByteTrack'in güven eşiklerinin hâkim hava koşullarına göre dinamik olarak uyarlanması performansı optimize edebilir. Şiddetli sis veya pusta, daha fazla potansiyel nesneyi tutmak için daha düşük bir eşik faydalı olabilirken, daha net koşullarda daha yüksek bir eşik yanlış pozitifleri azaltabilir. Nesne dedektörlerini ve ByteTrack'i açıkça sisli ve puslu senaryoları içeren veri kümeleri üzerinde eğitmek, bu koşullara karşı sağlamlıklarını ve genelleme yeteneklerini geliştirmek için çok önemlidir. Simülasyon teknikleri, sınırlı gerçek dünya olumsuz hava verilerini artırmada hayati bir rol oynayabilir.

Bu araştırmalar ve sonuçlar ışığında projenin ilerleyen safhalarında;

- Ön işleme adımı olarak görüntü dehazing'i içeren ByteTrack'in belirli adaptasyonları geliştirilecek ve değerlendirilecek,
- Sis ve pus altındaki sağlam takip için radar ve termal verilerin ByteTrack ile entegrasyonu araştırılacak ve farklı füzyon mimarileri (örneğin, erken füzyon, geç füzyon) üzerine araştırma yapılacaktır,
- Gerçek zamanlı hava durumu değerlendirmesine dayalı olarak ByteTrack için uyarlanabilir güven eşiği teknikleri araştırılacak,
- ByteTrack ve diğer ÇNT(Çoklu Nesne Takibi) algoritmalarını eğitmek ve karşılaştırmak için daha kapsamlı ve çeşitli sisli ve puslu koşullara ait veri kümeleri araştırılacak, uyarlanacaktır.

- [1] J. Liu, Y. Xie, Y. Z. 1 and H. Li, "Vehicle Flow Detection and Tracking Based on an Improved YOLOv8n and ByteTrack Framework," *World Electric Vehicle Journal*, vol. 1, p. 16, 2025.
- [2] J. Park, J. Hong, W. Shim, Jung and Dae-Jin, "Multi-Object Tracking on SWIR Images for City Surveillance in an Edge-Computing Environment," 13 Jul 2023.
- [3] Y. Zhang, P. Sun, Y. Jiang, D. Yu, F. Weng, Z. Yuan, P. Luo, W. Liu and X. Wang, "arxiv," 13 Oct 2021. [Online]. Available: <https://arxiv.org/abs/2110.06864>.
- [4] Z. Liu, C. Dai and X. Li, "An electric bicycle tracking algorithm for improved traffic management," *PubMed Central*, p. 10, 2024.
- [5] L. You, Y. Chen, C. Xiao, C. Sun and R. Li, "Multi-Object Vehicle Detection and Tracking Algorithm Based on Improved YOLOv8 and ByteTrack," *MDPI*, p. 13, 2024.
- [6] G. Zhang, J. Liu, Y. Zhao, W. Luo, K. Mei, P. Wang, Y. Song and X. Li, "A reliable unmanned aerial vehicle multi-ship tracking method," *PubMed Central*, p. 10, 2025.
- [7] N. A. Pandya and N. C. Chauhan, "Multi-Camera Person Tracking: Integrating YOLOv8 with ByteTrack," *SSRG International Journal of Electrical and Electronics Engineering* , pp. 53-60, 2024.
- [8] Y. Zhang, P. Sun, Y. Jiang, D. Yu and F. Weng, "ByteTrack: Multi-Object Tracking by Associating Every Detection Box," 2021.
- [9] Y. R. Suman, "How Computer Vision Powers Autonomous Vehicles," 2025.
- [10] L. V. Ma, M. I. Hussain, J. Park, J. Kim and M. Jeon, "arxiv," 04 Dec 2023. [Online]. Available: <https://arxiv.org/abs/2312.01650>.
- [11] S. Heer, S. Xu and A. Ku, "Mix and Match: ByteTrack with DETR," 2023.
- [12] A. Yasmeen and O. Daescu, "Recent Research Progress on Ground-to-Air Vision-Based Anti-UAV Detection and Tracking Methodologies: A Review," 2025.
- [13] A. K. Patil, B. Punugupati, H. Gupta, N. S. Mayur, S. Ramesh and P. B. Honnavalli, "Building the Future of Transportation: A Comprehensive Survey on AV Perception, Localization, and Mapping," 2025.
- [14] H. Toyman and A. Bajraktari, "Autonomous Agricultural Robot Using YOLOv8 and ByteTrack for Weed Detection and Destruction," 2025.
- [15] Y. Zhang, P. Sun, Y. Jiang, D. Yu, F. Weng, Z. Yuan, P. Luo, W. Liu and X. Wang, "ByteTrack: Multi-Object Tracking by Associating Every Detection Box," 2023.
- [16] D. Li, J. Sun, H. Wang, H. Shi, W. Liu and L. Wang, "Research on Haze Image Enhancement based on Dark Channel Prior Algorithm in Machine Vision," 2022.
- [17] N. Kirillova, M. J. Mirza, H. Bischof and H. Possegger, "Into the Fog: Evaluating Robustness of Multiple Object Tracking," 2024. [Online]. Available: <https://arxiv.org/abs/2404.10534>.